

Comparação de diferentes abordagens para resoluções do dataset cat's vs dog's

Comparing different approaches to solve Cat's vs Dog's dataset

Lucas Mrowskovsy Paim*

2019

Resumo

Este trabalho tem por objetivo criar uma rede neural de aprendizagem profunda para prever valores futuros de um papel na bolsa de valores, o papel escolhido foi PETR4 (Petrobras). A biblioteca utilizada para a criação das hipóteses foi a tensorflow, que segundo [Géron \(2019\)](#), é uma ótima biblioteca para cálculo número de código aberto, o modelo atingiu um erro médio de apenas R\$0,68, que apesar de ser baixo o mercado de ações é extremamente volátil, sendo necessário adicionar N outras características ao treinamento, sendo assim, não podendo ser utilizado em produção.

Palavras-chave: deep-learning. tensorflow. cnn. cats vs do.

Abstract

This work aims to create a deep learning neural network to predict future values of a role in the stock exchange, the role chosen was PETR4 (Petrobras). The library used for hypothesis creation was tensorflow, which according to [Géron \(2019\)](#), is a great open source number library. The model reached an average error of only R\$ 0.68, which despite being low the stock market is extremely volatile, being necessary to add N other characteristics to the training, so it cannot be used in production.

Keywords: deep-learning. tensorflow. cnn. temporal series.

*Programa de Pós Graduação em Inteligência Artificial, Curitiba - PR, 80215-901; Especializando em Inteligência Artificial Aplicada pela PUCPR; Tecnólogo em Sistemas para Internet pela Universidade Positivo; E-mail: lucasmpaim1@gmail.com

1 Introdução

Segundo [Géron \(2019\)](#), apesar de os computadores já terem conseguido feitos notáveis como vencer o campeão mundial de xadrez em 1996, eles ainda não conseguiam realizar tarefas triviais, como detectar um animal em uma foto, o que para nós humanos é algo extremamente trivial, isto ainda segundo [Géron \(2019\)](#) é devido ao nosso cérebro enviar para nosso subconsciente apenas informações de auto-nível, as redes neurais convolucionais (CNN), surgiram do estudo de nosso córtex visual e essas redes tem sido utilizadas como o principal meio para detecção de imagens desde então.

Neste trabalho será abordado algumas diferentes técnicas para a resolução do dataset cats vs dogs já pré-processada disponibilizada pelo Google na página do Tensorflow, onde foram removidas cerca de 1738 imagens corrompidas.

2 Método

O dataset utilizado por este trabalho, foi a "cats vs dogs" disponibilizada pelo Google em sua página da tensorflow, esta base contém 3 mil imagens de gatos e cachorros e seu propósito é ensinar a computadores a classificar fotos destes dois animais. A base está dividida em treinamento e validação, onde respectivamente temos, 2 mil imagens para treinamento e mil imagens para validação, ou seja, aproximadamente 30% da base voltada para validação.

As técnicas utilizadas para este trabalho são:

Transfer-learning baseada em extrator de características é utilizada uma rede previamente treinada como extrator de características, e estas são utilizadas para treinar modelos razos, como: SVM, KNN, etc.

Transfer-learning baseado em fine-tuning é utilizada uma rede previamente treinada, em que as camadas convolucionais do modelo são congeladas, e as camadas densas são retreinadas para o novo problema.

From scratch Criar e treinar um modelo a partir de um novo projeto, ou seja, sem reutilizar redes previamente treinadas.

2.1 Transfer Learning Shallow

O modelo pré-treinado utilizado por este trabalho é a Xception que é uma rede treinada utilizando a base [Imagenet \(2019\)](#), que é uma base de com milhares de imagens utilizada e alimentada pela comunidade científica.

Foram extraídos as características em arquivos CSV, esta extração resultou em 2048 características para cada uma das imagens, o dataframe de treinamento obteve o seguinte shape:

(2000, 2048)

Utilizando a técnica t-SNE, que segundo [Maaten \(2019\)](#), é uma técnica de redução de dimensionalidade estocástica, ou seja, utilizando esta técnica é possível reduzir um vetor de tamanho N para um de tamanho X , onde $X < N$, foi realizada a redução das bases de

características e apresentadas graficamente, para assim analisar o quão bem distribuídos estão as classes, estes gráficos podem ser conferidos na [Figura 1](#) e [Figura 2](#)

É possível notar estas características conseguem separar quase que perfeitamente as duas classes (gatos e cães), já na visão reduzida que temos na plotagem do t-SNE, com isso não é necessário um modelo muito robusto para que se obtenha resultados satisfatórios.

O modelo shallow escolhido para este trabalho é o Naive Bayes.

Segundo, [Britto \(2019\)](#), o teorema de Bayes consiste em uma abordagem probabilística para aprendizagem, calculando assim a probabilidade de uma característica X de um vetor de prever determinada classe.

A técnica de Naive Bayes, assume que todas as características no vetor são independentes, por isso, é chamado de Naive (do inglês Ingênuo), pois determinadas características podem estar relacionadas entre si, o que faz com que essa técnica tenha um resultado inferior a técnica de Redes Bayesianas que consideram que os atributos podem ou não ser relacionados, isto é, a característica X pode ou não estar diretamente relacionada a característica Y .

2.1.1 Resultados do Treinamento

Como esperado, o resultado foi extremamente satisfatório, conseguindo até 97,6% de acurácia.

Acurácia Naive Bayes Validação: 0.976

A matrix de confusão pode ser consultada na: [Figura 3](#).

2.2 Transfer Learning - Fine Tuning

Referências

BRITTO, A. *Aprendizagem Bayesiana*. 2019. Ppgia. Disponível em: <<http://www.ppgia.pucpr.br/~alceu/am/4%20-%20Naive%20Bayes%20and%20Bayesian%20Networks/NaiveBayes.pdf>>. Acesso em: 25 set 2019. Citado na página 3.

GÉRON, A. *Mãos à obra: Aprendizagem de máquina com Scikit-Learn e Tensorflow*. 1. ed. Rio de Janeiro: Alta Books Editora, 2019. Acesso em: 21 ago 2013. Citado 2 vezes nas páginas 1 e 2.

IMAGENET. Imagenet. In: . [s.n.], 2019. Disponível em: <<http://www.image-net.org/about-overview>>. Acesso em: 16 fev 2019. Citado na página 2.


MAATEN, L. van der. *Aprendizagem Bayesiana*. 2019. Lvdmaaten. Disponível em: <<https://lvdmaaten.github.io/tsne/>>. Acesso em: 25 set 2019. Citado na página 2.

Figura 1 – TSNE - Treinamento - TransferLearning Shallow



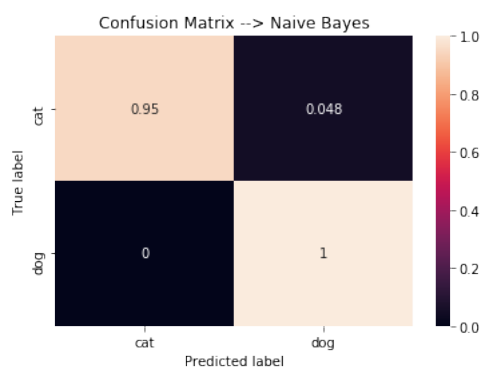
Fonte: O Autor

Figura 2 – TSNE - Validação - TransferLearning Shallow



Fonte: O Autor

Figura 3 – Matrix de confusão - Naive Bayes - Normalizada



Fonte: O Autor